



哈尔滨工程大学学报

Journal of Harbin Engineering University

ISSN 1006-7043, CN 23-1390/U

《哈尔滨工程大学学报》网络首发论文

题目: 利用卷积神经网络分类乳腺癌病理图像
作者: 于凌涛, 夏永强, 闫昱晟, 王鹏程, 曹伟
收稿日期: 2019-09-17
网络首发日期: 2021-02-10
引用格式: 于凌涛, 夏永强, 闫昱晟, 王鹏程, 曹伟. 利用卷积神经网络分类乳腺癌病理图像. 哈尔滨工程大学学报.
<https://kns.cnki.net/kcms/detail/23.1390.U.20210209.1511.004.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

利用卷积神经网络分类乳腺癌病理图像

于凌涛, 夏永强, 闫昱晟, 王鹏程, 曹伟

(哈尔滨工程大学 机电工程学院, 黑龙江 哈尔滨 150001)

摘要: 为了解决乳腺病理图像分类准确率低, 耗时费力的问题, 本文提出了利用卷积神经网络 (CNN) 对乳腺病理图像进行分类的方法。利用该方法将病理图像快速、自动划分为良性和恶性两类。采用基于 Inceptionv3 架构的卷积神经网络模型和迁移学习算法进行病理图像特征提取; 利用全连接层神经网络和 SoftMax 函数进行图像分类。同时针对高分辨率图像提出了图像分块化思想, 将每块的分类概率通过加和、乘积、取最大值 3 种算法进行整合, 得出图像最终分类结果。利用 BreaKHis 公共数据集对所提出的分类方法进行了实验验证。结果显示对于 4 个放大系数的图像分类准确率分别达到约 95.0%、95.1%、94.1% 和 92.3%, 该方法有效提高了乳腺癌病理图像分类准确率。

关键词: 乳腺癌; 病理图像; 卷积神经网络; 迁移学习; 深度学习; 图像分块; 融合算法; 图像分类

Doi: 10.11990/jheu.201909052.

中图分类号: TP181

文献标识码: A

文章编号: 1006-7043 (2006) xx-xxxx-x

Breast cancer pathological image classification based on convolutional neural network

YU Lingtao, XIA Yongqiang, YAN Yusheng, WANG Pengcheng, CAO Wei

(College of Mechanical and Electrical Engineering, Harbin Engineering University, Harbin 150001, China)

Abstract: To solve the problem of low accuracy and time-consuming and laborious classification of breast pathological images, this paper proposes a method of using convolutional neural network (CNN) to classify breast pathological images. This method is used to quickly and automatically divide pathological images into benign and malignant categories. First, the convolutional neural network model based on the Inceptionv3 architecture and the transfer learning algorithm are used for pathological image feature extraction; secondly, the fully connected layer neural network and SoftMax function are used for image classification. At the same time, the idea of image partitioning is proposed for high-resolution images. The classification probability of each block is integrated through three algorithms: summation, product, and maximum, to obtain the final classification result of the image. Experiments were carried out on BreaKHis public dataset, and the accuracy reached 95.0%, 95.1%, 94.1% and 92.3% respectively on the four magnification coefficients. It shows that the method effectively improves the classification accuracy of breast cancer pathological images.

Keywords: Breast cancer; Pathological image; Convolutional Neural Network; Transfer learning; Deep learning; Image blocking; Fusion algorithm; Image classification

癌症是当今世界重要的公共健康问题。根据世界卫生组织国际癌症研究机构的数据显示, 2018 年约有 1810 万新病例和 960 万癌症相关死亡病例, 影响到所有国家和地区的人口。尤其是乳腺癌在女性癌症新发病例占比最高 (占比 24.2%), 而且死亡率非常高^[1]。

病理组织学分析仍然是诊断乳腺癌最广泛使用

的方法^[2], 而且大多数诊断仍由病理学家在显微镜下对组织学样本进行目视检查来完成, 这不仅需要高度专业的病理学家的大量工作。专家之间的诊断一致性平均约为 75%^[3], 运用计算机来进行病理组织学图像的自动分类是一个值得研究的课题。不仅可以使乳腺癌诊断更快, 而且更不容易出错。目前关于乳腺癌识别的研究主要分为 2 种方法: 1) 基于手工特征提取结合传统机器学习的方法。Belsare 等^[4]使用统计纹理特征训练 K-NN (k 近邻) 和支持向量机 (support vector machine, SVM) 分类器, 在一个 40 倍放大的私人乳腺组织学数据集上达到了 70%~100% 的准确率。Spanhol 等^[5]公开了乳腺癌

收稿日期: 2019-09-17.

基金项目: 黑龙江省自然科学基金项目 (LH2019F016)。

作者简介: 于凌涛, 男, 副教授;

夏永强, 男, 博士研究生。

通信作者: 夏永强, xyq2017@hrbeu.edu.cn.

病理图像数据集 BreakeHis, 研究了 6 种包括邻接阈值统计^[6]在内的手工提取的纹理特征结合包含 SVM 在内的 4 种分类器共 24 组的分类性能, 作为区分良性和恶性肿瘤的参考基线, 达到了 80%~85% 的准确率; 2) 基于深度学习的分类方法, 深度学习使得模型可以直接从输入的图片中提取特征, 避免了人工提取特征的程序, 节省了大量的人力物力。近年来, 卷积神经网络 (convolutional neural networks, CNN) 作为深度学习的重要方法在图像识别领域取得了巨大的成功, 其在医疗图像分析方面也取得了快速的发展^[7]。Araújo 等^[8]利用卷积神经网络将乳腺癌病理图像分成了癌和非癌 2 大类, 最高达到了 88.3% 的识别率。进一步划分为正常组织、良性病变、原位癌和浸润性癌 4 类时, 最高达到了 77.8% 的总体准确率。何雪英等^[9]使用卷积神经网络模型对 BreakeHis 数据集进行了良性和恶性分类, 经过数据增强处理之后的识别率最高可达到 91%。Spanhol 等^[10-11]在 BreakeHis 数据集上采用卷积神经网络和深度特征的方法将乳腺癌组织病理图像分为良性和恶性 2 类, 最高分别达到了 90% 和 86.3% 的准确度。Bayramoglu 等^[12]提出了 1 种与放大系数无关的乳腺癌组织病理图像分类方法, 该方法在 BreakeHis 数据集上, 可同时分类病理图像的良性或恶性和分类放大倍数, 其实验结果在良性或恶性分类上达到了 84.3% 的准确度。

为了进一步提高乳腺病理图像分类精度, 本文提出了基于卷积神经网络的乳腺癌病理图像分类方法, 同时针对高分辨病理图像提出了图像分块的思想,

并在 BreakeHis 数据集上, 验证了此方法的性能。

1 BreakeHis 数据集

BreakeHis 数据集^[5]是巴拉那联邦大学的 Spanhol 等论文中发布的公开数据集。该数据集采集自 82 个病人, 其中良性 24 人, 恶性 58 人。目前为止, 该数据集一共包含 7 909 张图片, 分为 4 个放大系数 40×, 100×, 200×, 400×。每个放大系数又可分为良性和恶性肿瘤 2 大类。具体分布情况如表 1 所示。

乳腺良性和恶性肿瘤在显微镜下又可根据肿瘤细胞的不同分为不同类型, 但本文只研究不同放大系数下的良性和恶性二元分类问题。图 1 展示了 40×放大系数下的部分病理图像, (a)~(d) 图像为 4 种良性肿瘤, (e)~(h) 为 4 种恶性肿瘤。所有图像存储格式为三通道 RGB 格式, 固定尺寸为 700×460 像素。

表 1 按放大系数和类别的图像分布

Table 1 Image distribution by magnification factor and class

放大系数	良性	恶性	总计
40×	625	1370	1995
100×	644	1437	2081
200×	623	1390	2013
400×	588	1232	1820
总计	2480	5429	7909
患者人数	24	58	82

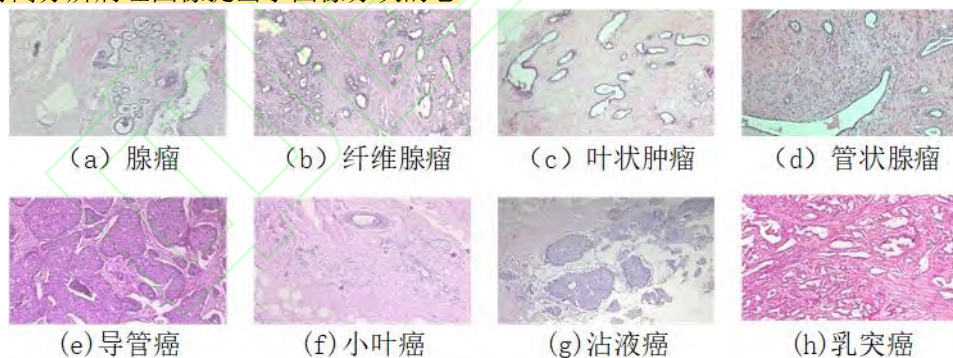


图 1 乳腺癌组织病理学图像样本

Fig.1 Sample breast cancer histopathology image

2 图像分类方法

2.1 基于迁移学习的特征提取和图像分类

随着深度学习的快速发展, 在图像识别领域, 深度学习特别是采用 CNN 的方法已经优于传统的机器学习方法。CNN 体系结构的主要由 3 种层构成: 卷积层、池化层和全连接层。卷积层是用 1 组参数可学习的滤波器对输入图像进行卷积运算, 每个滤波器经过运算产生 1 个特征映射。池化层对输入特征映射进行向下采样以降低输入的空间维度。全连接层一般用在模型末端, 用来将前边提取到的特征综合起来进行分类等操作。通常, 一个完

整的 CNN 架构是通过各种方式叠加这些层来获得的。如 LeNet-5^[13]模型, 运用 CNN 模型结构进行图像分类实例, 它对输入尺寸为 32×32 的灰度图像进行 2 次卷积加池化操作, 最后加上 3 层全连接层进行图像的 10 分类。

目前, 各大研究机构相继发布了一些 CNN 模型结构, 如 LeNet、VGG、AlexNet 和 ResNet 等, 这些模型都曾在图像识别上取得过优异的成绩。在一些数据集上的识别上, 基于这些成熟的模型来构建模型, 往往比自己从头搭建模型效果更好, 更方便快捷。如基于 AlexNet 模型进行了乳腺图像的特征提取^[10], 该模型相对简单, 限制了其分类精度。

故本文基于结构更加复杂的 Inception V3^[14]模型搭建模型, 进行病理图像的分类。

如图 2 所示, 模型由特征提取过程和分类过程构成。因为 InceptionV3 模型针对图片大小为 299×299 搭建, 所以采用图像缩放和 Inception V3 模型构成特征提取过程, 其中 InceptionV3 模型不包含原模型最后 2 层全连接层。分类过程由 2 层新的全连接层神经网络构成, 其中第 1 层全连接层神经网络具有 512 个节点, 第 2 层具有 2 个节点, 并在最后 1 层神经网络采用 SoftMax 函数作为激活函

数进行分类。

单张图像分类具体操作步骤为: 1) 将图片通过缩放使尺寸大小固定为 299×299; 2) 将缩放后的图片送入 InceptionV3 模型进行计算, 取 InceptionV3 模型最后一层池化层的输出参数作为图片的特征向量, 其尺寸为 1×2 048; 3) 将特征向量送入全连接层神经网络进行计算, 第 2 层每个节点的数值经过 SoftMax 函数计算之后的输出结果即为输入图像属于某一类的概率; 4) 将图像分类到输出概率最大的类别。

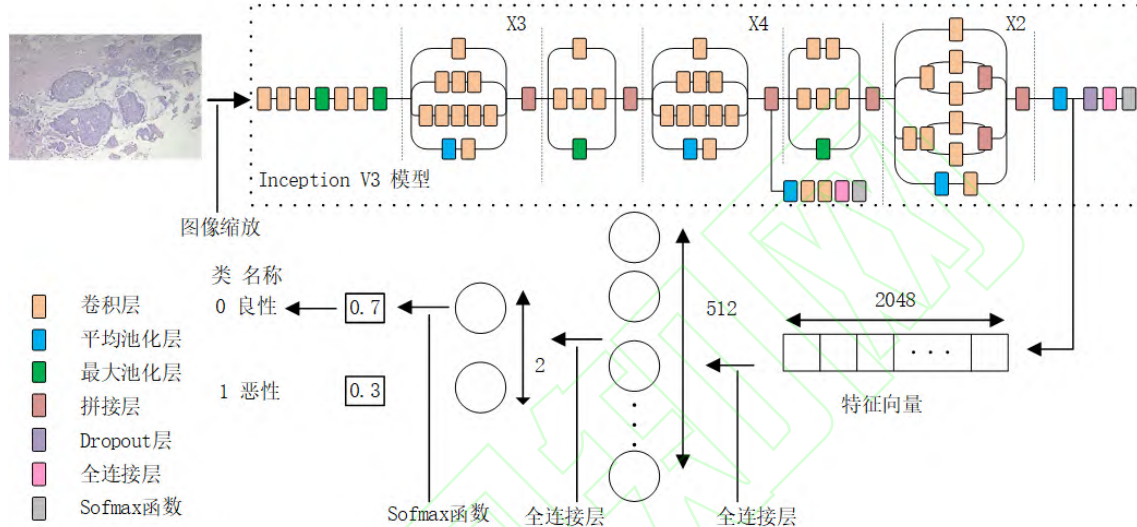


图 2 图像基于 Inception V3 模型分类过程

Fig.2 Image classification based on Inception V3 model

由于数据量的限制, 本文只训练特征提取之后 2 层全连接层的参数。对于特征提取阶段 Inception V3 模型的参数, 采用了迁移学习^[15]的方法获得。迁移学习是先在 1 个大型数据集上训练 CNN 模型的参数, 然后将训练好的参数作为在新的数据集训练相同 CNN 模型的初始化权值, 迁移学习又可分为微调 and 固定权值的 2 种方式, 微调方式在每轮训练之后对 CNN 模型的参数进行更新, 而固定权值的方式是 CNN 模型参数在初始化之后便固定不变。

本文采用在 ImageNet^[16]数据集上训练的 Inception V3 模型参数作为特征提取阶段模型的初始化权值。且微调方式导致模型参数的改变, 使得每次训练都需要重新计算图像的特征向量, 计算任务大、训练时间长, 故本文采用固定权值的方法。由此本文在计算出图像特征向量之后将其存储为文本文档, 这样可使本张图片在下轮训练过程中, 可直接读取文本文档获得特征向量, 避免重复特征提取过程的计算, 节约计算时间。

在训练过程中, 采用通过构建 SoftMax 函数的输出结果与图像标签之间的交叉熵作为损失函数, 通过梯度下降法进行全连接层神经网络的参数优化, 进而对损失函数进行最小化。单张图片交叉熵损失函数为:

$$L(x, y) = -\sum_i y_i \log p_i(x) \quad (1)$$

式中: $p_k(x)$ 是输入图像 x 被分类器分为第 k 类的概率; y_k 是指示性函数, 当输入图像 x 的标签 y 是 k 类时 $y_k=1$, 否则 $y_k=0$ 。

2.2 基于四叉树图像分割的数据增强

在训练 CNN 模型时, 若使用的数据集的样本数较少, 该网络容易过度拟合。常用的方法为数据增强。数据增强是通过旋转、翻转、滑动窗口等操作提升数据量, 本文采用更适合高分辨率图像的基于四叉树分割的数据增强方法^[17]。四叉树由 1 个连续的结构组成, 在每一层, 将上一层的输入图像均等分成 4 个部分。即在每一级 L ($L \geq 1$) 处, 将输入图像划分为 $(2^{L-1})^2$ 个大小相等且不重叠的块。这意味着在第 1 级输入图像保持为原始图像, 在第 2 级输入图像被分成 4 个图像, 在第 3 级输入图像被分成 16 个图像, 依此类推, 如图 3 所示。本文对乳腺图像的第 2 级和第 3 级切分结果进行了研究, 即每张图片分割为 4 块和 16 块。经过分割之后训练数据分别增加为原数据量的 4 倍和 16 倍, 在分割之后, 每块子图像都被认为与原始图像具有相同的类标签。




图 3, 基于四叉树方法的图像分割方法
Fig.3 Image cutting method based on quadtree

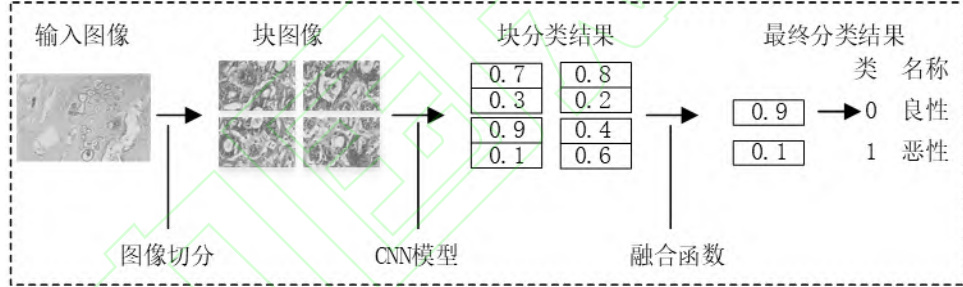


图 4 图像完整分类过程

Fig.4 Image integrity classification process

3 实验分析

本文中所有试验均在相同试验环境下完成, 试验平台为 1 台 CPU 为 Intel I7-8700, GPU 为 NVIDIA GTX1060 6GB 显存, 内存为 16GB 的计算机, 试验环境为 Windows 10 操作系统, 基于 Python 语言的 TensorFlow 架构进行编程。

3.1 实验细节与评价标准

本文将实验数据集按照 75%、15%、15% 的比例切分为训练集、验证集、测试集。训练集用来训练模型, 验证集用来调节模型的超参数。模型的超参数选定之后, 合并使用训练集和验证集的数据进行重新训练模型, 利用测试集来输出测试结果。本文中实验结果为 5 次测试结果的平均取值, 且 5 次实验独立进行, 每次实验前重新随机划分训练集、验证集和测试集。

实验结果以乳腺病理图像在图像层面和病人层面的分类准确率作为评价标准, 并在每个放大系数

2.3 融合算法

由于采用了基于四叉树的图像分割方法, 一张图片被分割成多个子图像块, 每个图像块在经过模型计算可能产生不同的分类结果, 故需要融合算法将所有图像块分类结果整合起来, 常用的算法有和规则、乘积规则、最大值规则、多数投票规则等。为了研究不同的融合算法对乳腺图像分类结果的影响, 本文选取了和规则、乘积规则和最大值规则^[18]算法进行了实验验证, 算法计算过程为:

$$\text{和规则: } \phi = \arg \max_{k=1}^K \sum_{i=1}^N p_i(k) \quad (2)$$

$$\text{乘积规则: } \phi = \arg \max_{k=1}^K \prod_{i=1}^N p_i(k) \quad (3)$$

$$\text{最大值规则: } \phi = \arg \max_{k=1}^K \max_{i=1}^N p_i(k) \quad (4)$$

式中: $p_i(k)$ 表示为 1 张图片的第 i 个子图像块被模型分为 k 类的概率值; K 表示分类类别总数; N 表示 1 张图片被切分块的数量。图 4 展示 1 张病理图片的完整分类示例过程, 在本例中将原始图像分割为 4 块, 采用的融合函数为最大值规则。

上独立评估。基于图片层面的分类准确率只是考虑分类正确的图像占全部图像的比例, 图像层面分类准确率 I_A 为:

$$I_A = \frac{N_c}{N_{im}} \quad (5)$$

式中: N_{im} 表示全部图片的数量; N_c 是分类正确的图片数量。

基于病人层面的分类准确率则先对每个患者的多张病理图像计算分类准确率, 再对所有患者的分类准确率取平均值。病人层面分类准确率 P_A 为:

$$P_A = \frac{\sum_{p=1}^{N_p} \frac{N_c^p}{N_{im}^p}}{N_p} \quad (6)$$

式中: N_p 是患者的数量; N_c^p 是对应患者 P 分类正确的图片数量; N_{im}^p 是对应患者 P 图片的总数。

3.2 实验结果与对比

3.2.1 实验结果

根据 3.1 所定义的实验细节和评价标准, 本节在 BreaKHis 数据集上进行本文提出的乳腺病理图像识别方法的性能验证实验, 实验结果如表 2 和表 3 所示。表 2 和表 3 分别展示了测试集在图像层面和病人层面的识别准确度。从实验结果上看, 将图片基于四叉树策略分割后, 无论 4 切分还是 16 切分, 准确度都明显高于原图, 其中 4 切分提高了 2.0% 到 4.4% 的准确率, 16 切分提高了 0.9% 到 4.9% 的准确率。说明图片分割方法结合融合算法能有效提升乳腺病理图像识别准确度。

而从实验结果上并不能得出哪一个融合算法更适合本实验, 说明采用不同的融合算法规则对实验结果的影响很小。通过对比不同放大系数之间的实验数据, 发现 100×放大系数下的识别率最高, 400×放大系数下的识别率最低, 40×放大系数略高于 200×放大系数的识别率。

表 2 图像层面的准确率

Table 2 Accuracy at picture level

切分方法	融合算法	放大系数			
		40×	100×	200×	400×
原图	—	92.8	90.7	91.8	88.67
4 切分	和规则	95.0	95.1	93.8	92.2
	积规则	95.0	94.5	94.1	92.3
	最大值规则	94.2	93.7	94.1	92.0
16 切分	和规则	93.7	95.5	92.6	91.26
	积规则	93.9	95.6	93.0	91.3
	最大值规则	93.7	95.5	93.7	90.4

表 3 病人层面的准确率

Table 3 Accuracy at Patient level

切分方法	融合算法	放大系数			
		40×	100×	200×	400×
原图	—	93.1	90.6	92.5	88.0
4 切分	和规则	95.0	94.6	94.3	92.2
	积规则	94.9	94.2	94.5	92.3
	最大值	94.2	93.3	94.4	91.8
16 切分	和规则	94.0	94.1	91.4	91.2
	积规则	94.2	94.8	91.9	91.3
	最大值规则	94.0	94.6	92.8	91.0
	最大值规则	94.0	94.6	92.8	91.0

图 5 展示了 100×放大系数下使用原图和 16 切分的病理图像在训练过程中的损失函数随着训练步数的变化曲线, 为了便于观察, 曲线经过平滑处理。可以看出, 在原图的情况下, 本该逐渐减小收敛的损失函数却在训练步数大约达到 2 000 步时达到最小值, 随后开始增大。这说明模型在训练步数超过 2 000 时开始过拟合。而在 16 切分情况下, 损失函数是逐渐下降并收敛的, 说明图像切分扩大了训练数据量, 避免了过拟合情况的发生, 这也是图像切

能提高识别准确度的原因之一。




图 5 原图和 16 切分图像的损失函数对比

Fig. 5 Loss function comparison between original image and 16-sliced image

4 切分的结果除了在 100×放大系数上都要略高于 16 切分的结果。这是由于图片切分的过小, 导致的单张子图片所包含的信息不足以体现病理情况。如图 6 所示, a, b 两图分别来自于 40×放大系数下 16 切分良性和恶性的病理图片, 从图上可以看出, 其已经不含有细胞核等可提供分类特征的结构。还有的图片切分之后只含有脂肪细胞, 同样影响分类精度。



(a) 良性病例

(b) 恶性病例

图 6 40×放大倍数下 16 切分病理图像错误分类示例

Fig.6 Examples of 16-slice pathological images under 40× magnification

3.2.2 与其他实验对比

为了更好的评估实验结果, 我们选取了文献[5, 10-12]和本文中各个放大系数中最好的实验结果进行对比, 如表 4 所示。文献[12]中未展示图片层面识别准确度。从表中可以看到基于卷积神经网络和四叉树图片切分的方法, 在各个放大系数上达到了最高的识别准确度。相对[5]中采用手工特征提取和传统的机器学习的方法, 本文的方法提高了 9.9% 到 12.2% 的图像识别准确度; 相对[9]采用卷积神经网络提取特征, 旋转、翻转的方法增强数据, 本文的方法提高了 2.3% 到 5.1% 的图像识别率; 相对[10]中采用卷积神经网络提取特征, 滑动窗口数据增强的方法, 本文的方法提高了 5% 到 11.5% 的图像识别率; 相对[11]中采用深度特征和特征融合的方法, 本文的方法提高了 8.2% 到 10.9% 的图像识别率; 相对[12]中采用多任务卷积神经网络的方法, 本文方法提高了 10.2% 到 12% 的图像识别率。并且经过试验结果对比可以得出, 基于卷积神经网络特征提取的方法, 在分类性能上要优于手工特征提取的方法。

表 4 与其他方法的实验结果比较
Table 4 Comparisons with experimental results of other methods

评价指标	文献	放大系数			
		40×	100×	200×	400×
图片层面	文献[5]	82.8	80.7	84.2	81.2
	文献[9]	90.9	91.0	91.0	91.0
	文献[10]	89.6	85.0	84.0	80.8
	文献[11]	84.6	84.8	84.2	81.6
	本文	95.0	95.1	94.1	92.3
病人层面	文献[5]	83.8	82.1	85.1	82.3
	文献[9]	91.0	90.0	91.0	91.0
	文献[10]	90.0	88.4	85.3	86.1
	文献[12]	83.0	83.1	84.3	82.1
	文献[11]	84.0	83.9	86.3	82.1
	本文	95.0	94.8	94.5	92.3

4 结论

1) 图像分割的数据增强方法能够明显提高乳腺图像识别率; 四切分的性能要高于十六切分。

2) 不同融合算法对分块图像识别率的影响较小。通过与其他相关方法的对比, 验证了利用深度学习提取特征的性能要优于基于视觉的手工特征。

未来的工作是 (1) 优化图像的特征提取方法, 如采用多模型提取特征结合特征融合的方法。(2) 通过优化图片的切分方法, 数据增强方法, 进一步提高分类的精度。(2) 在二分类的基础上, 对于良性和恶性肿瘤进行进一步的分类, 做到细分。

参考文献:

- [1] Freddie Bray, Jacques, et al. Global cancer statistics 2018: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries.[J]. CA: A CancerJournal for Clinicians, 2018.
- [2] Yang F , Li J . WHO classification of tumors of the breast[J]. Zhonghua wai ke za zhi [Chinese Journal of Surgery], 2014, 52(1):1..
- [3] Elmore J G , Longton G M , Carney P A , et al. Diagnostic concordance among pathologists interpreting breast biopsy specimens[J]. JAMA, 2015, 313(11):1122. <https://doi.org/10.1001/jama.2015.1405> PMID: 25781441
- [4] Belsare A D , Mushrif M M , Pangarkar M A , et al. Classification of breast cancer histopathology images using texture feature analysis[C]// TENCON 2015 - 2015 IEEE Region 10 Conference. IEEE, 2015.
- [5] Spanhol F A , Oliveira L S , Petitjean C , et al. A dataset for breast cancer histopathological image classification[J]. IEEE Transactions on Bio-medical Engineering, 2015, 63(7):1455-1462.
- [6] Pantelic R S , Hamilton N A , Kelly H , et al. Fast automated cell phenotype image classification[J]. BMC Bioinformatics, 2007, 8(1):1-8.
- [7] Zhang Y , Yu H . Convolutional Neural Network based metal artifact reduction in X-ray computed tomography[J]. IEEE Transactions on Medical Imaging, 2018:1-1.
- [8] Araújo Teresa, Guilherme A , Eduardo C , et al. Classification of breast cancer histology images using Convolutional Neural Networks[J]. PLOS ONE, 2017, 12(6):e0177544-.
- [9] 何雪英, 韩忠义, 魏本征. 基于深度学习的乳腺癌病理图像自动分类[J]. 计算机工程与应用, 2018, v.54; No.907(12):126-130.
He Xueying, Han Zhongyi, Wei Benzhen. Automatic classification of breast cancer pathological images based on deep learning [J]. Computer Engineering and Applications, 2018, v.54; No.907 (12): 126-130.
- [10] Spanhol F A , Oliveira L S , Petitjean C , et al. Breast cancer histopathological image classification using Convolutional Neural Networks[C]// International Joint Conference on Neural Networks. IEEE, 2016.
- [11] Spanhol F A , Oliveira L S , Cavalin P R , et al. Deep features for breast cancer histopathological image classification[C]// 2017 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2017.
- [12] Bayramoglu N , Kannala J , Janne Heikkilä Deep learning for magnification independent breast cancer histopathology image classification[C]// International Conference on Pattern Recognition. IEEE, 2017.
- [13] Lecun Y , Bottou L , Bengio Y , et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [14] Szegedy C , Vanhoucke V , Ioffe S , et al. Rethinking the inception architecture for computer vision[J]. [IEEE 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) - Las Vegas, NV, USA (2016.6.27-2016.6.30)] 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) 2016:2818-2826..
- [15] Yosinski J , Clune J , Bengio Y , et al. How transferable are features in deep neural networks?[C]// Advances in Neural Information Processing Systems. MIT Press, 2014.
- [16] Deng J , Dong W , Socher R , et al. ImageNet: A large-scale hierarchical image database[C]// 2009 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR 2009), 20-25 June 2009, Miami, Florida, USA. IEEE, 2009.
- [17] Vamvakas G , Gatos B , Perantonis S J . Handwritten character recognition through two-stage foreground sub-sampling[J]. Pattern Recognition, 2010, 43(8):2807-2816.
- [18] Kittler J , Hatef M , Duin R P W , et al. On combining classifiers[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 1998, 20(3):226-239.